

复现说明

本文全部数字由五个脚本产生，共用同一套划分与随机种子。一条命令跑完：

```
cd /mmfs1/data/group/pmc050/yding/gad_reasoning
sbatch scripts/run_all_evals.sh      # 约 3.5 小时；勿在登录节点直接运行
```

1 环境

组件	版本
Python	3.10.18 (conda 环境 <code>geochem</code>)
解释器绝对路径	<code>/mmfs1/data/group/pmc050/yding/miniconda3/envs/geochem/bin/python</code>
numpy	2.2.6
scipy	1.15.3
scikit-learn	1.7.2
pandas	2.3.3
xgboost	3.2.0
shap	0.49.1
reportlab / pypdfium2 / fonttools	项目本地 <code>.cache/pylibs</code> （仅供出图，与结果无关）

`xgboost`、`shap`、`reportlab` 等装在项目内 `.cache/pylibs`，脚本自行 `sys.path.insert`，不污染共享 conda 环境。重建方式：

```
export PIP_CACHE_DIR=$PWD/.cache/pip
$PY -m pip install --target $PWD/.cache/pylibs shap reportlab pypdfium2 fonttools
```

2 数据

用途	路径
化探（5 类样品）	<code>datasets/geochemical/states/state_geochemical/gswa_all_*.csv</code>
已知矿点（每金属）	<code>datasets/geochemical/states/sites_enriched/enriched_<El>_sites.csv</code>
他矿种矿点（true-nonmine 负样本）	<code>datasets/geochemical/states/sites/no_gold/no_<el>_sites.csv</code>
地球物理栅格	<code>datasets/selected_layers/rasters/</code>
构造/地质矢量	<code>datasets/selected_layers/vectors/</code>

3 固定参数（ `scripts/eval_comprehensive.py` 顶部 ）

参数	值	含义
SEED	42	主种子；派生 $seed = 42 + k$ ，各场景固定
MAX_TEST	30	每金属 held-out 正样本数
N_NEG	200	每场景负样本数
N_TRAIN_NEG	300	训练背景点数（= 专家树 <code>n_bg</code> ）
BUFFER_KM	5.0	负样本距 test 正样本的最小距离
FAR_KM	50.0	far-random 距任何已知矿点的最小距离
SPATIAL_BOUNDARY	-25.0	纬度分界：南训北测
N_BOOT	10	归因稳定性的 bootstrap 次数
N_REP	5 / 3	缺失模态 / 选择性预测的随机子集重复数

派生种子对照：train_neg=142、random=43、far_random=44、true_nonmine=45、spatial 负样本=47、spatial agent=52、bootstrap b=1042+b。

4 脚本与产出

脚本	产出	耗时
eval_comprehensive.py	eval_comprehensive_summary.json、eval_scores.json	~45 min
eval_baselines.py	eval_baselines_summary.json	~55 min
eval_interpretability.py	eval_interpretability_summary.json	~30 min
eval_explanation_quality.py	eval_explanation_quality.json	~50 min
eval_degradation.py	eval_degradation.json	~15 min
eval_confidence.py	eval_confidence.json	~15 min
report_baselines.py	eval_baselines.md	秒级
md2pdf.py	任意 md → PDF（中文，无需 pandoc/latex）	秒级

单金属调试：所有评测脚本均支持 `--metals Cu`。

5 论文数字 → 出处对照

论文中的数字	来源文件	JSON 路径
专家树 9 金属 × 4 场景 AUC	eval_baselines_summary.json	<metal>.<scenario>.expert_tree.auc
baseline 同口径 AUC	同上	<metal>.<scenario>.featuresets.expert_matched.<model>.auc
训练/测试正样本空间距离	同上	<metal>._leakage.random_split

论文中的数字	来源文件	JSON 路径
spatial 划分距离	eval_baselines_spatial_leakage.json	<metal>
根重构误差 = 0、权重查找失败率 = 0	eval_interpretability_summary.json	results.<metal>.additivity / .z_sanity
专家级 Hit@1 = 0.904	同上	results.<metal>.ablation_consistency.hit_at_1
归因稳定性 0.631	eval_explanation_quality.json	<metal>.<model>.stability_top3_jaccard
组级忠实度 ρ / Hit@1	同上	<metal>.<model>.faithfulness_group
解释单元数 n80	同上	<metal>.<model>.parsimony_n80
confidence 随缺失单调 ($\rho = -1.00$)	eval_degradation.json	<metal>.curve.<k>._expert_confidence
选择性预测 auc@25、 ρ_{err}	eval_confidence.json	<metal>.<model>

6 已知问题

1. REE 配置有缺陷：化探表中无 REE 元素列（只有 Ce/Dy/Er/Eu 等单元素），目标富集专家空转，仅 34 个特征、7 个活跃专家。REE 的数字须标注此限制或先做元素聚合。
2. Mn 在 spatial 上 AUC = 0.269（显著低于随机，方向学反），须解释或剔除。
3. eval_degradation.py 曾在 REE 上因 None 格式化崩溃，已修；REE 一行需补跑。
4. agent 层幻觉率评测从未运行：demo/paper 的 Table 2 为占位符，demo/eval/prompts 与 demo/eval/results 为空目录。
5. 训练/测试正样本之间无空间隔离（详见 reports/summary_table.md）。random / far-random / true-nonmine 应表述为近矿（brownfield）排序能力，spatial 才是跨区域外推。

7 复现校验

跑完后用以下断言核对（数值应逐位一致，随机性已全部固定）：

```
import json
b = json.load(open('reports/eval_baselines_summary.json'))
assert abs(b['Cu']['far_random']['expert_tree']['auc'] - 0.925) < 1e-3
assert abs(b['Cu']['far_random']['featuresets']['expert_matched']['random_forest']['auc'] - 0.995) < 1e-3
e = json.load(open('reports/eval_explanation_quality.json'))
assert abs(e['Cu']['expert_tree']['stability_top3_jaccard'] - 0.649) < 0.02 # bootstrap 有微小抖动
i = json.load(open('reports/eval_interpretability_summary.json'))['results']
assert all(v['additivity']['root_recon_err_max'] == 0.0 for v in i.values())
```